Human-in-the-loop mailbot i servicekommunikation: Arkitektur, risk och organisatoriska konsekvenser

Jörgen Hansson, Ph.D.

2025-12-26, ver 1.0

Dokumentpositionering

Detta dokument är en teknisk och organisatorisk genomlysning av användning av generativ AI i emailbaserad servicekommunikation, med särskilt fokus på *human-in-the-loop* som designprincip.

Rapporten är avsedd att fungera som:

- normerande referensdokument
- beslutsunderlag för ledning och styrelse
- teknisk vägledning för arkitektur och införande

Dokumentet är **inte**:

- ett marknadsdokument
- en produktbeskrivning
- en fullständig implementeringsmanual

Analysen bygger på etablerad forskning inom sociotekniska system, beslutsstöd, human–AI-interaktion och AI-governance, kompletterad med ett tekniskt study case i servicekontext.

Revisionshistorik

Version	Datum	Förändring
v1.0	[datum]	Första frysta versionen

Table of Contents

Sammanfattning 8
1. Bakgrund och motiv 9
1.1 AI i serviceorganisationer: ett förskjutet problem 9
1.2 Varför golfklubbar är en relevant studiearena 9
2. Syfte, avgränsning och angreppssätt 9
2.1 Syfte 9
2.2 Avgränsning 10
2.3 Angreppssätt 10
3. Email som organisatoriskt nervsystem 10
3.1 Inledning 10
3.2 Email som beslutsyta snarare än informationskanal 10
3.3 Asynkronicitet, tolkning och risk 11
3.4 Email som bärare av organisatorisk praxis 12
3.5 Konsekvenser för AI-stödd automation 12
3.6 Sammanfattning 13
4. AI i serviceorganisationer: etablerade felslut 13
4.1 Inledning: varför felsluten upprepar sig 13
4.2 Felslut 1: ”AI sparar alltid tid” 13
4.3 Felslut 2: ”Chat är ett bättre gränssnitt än email” 14
4.4 Felslut 3: ”Bättre formulering ger bättre svar” 14
4.5 Felslut 4: ”Mer data och bättre modeller löser problemen” 15
4.6 Felslut 5: ”Automation är alltid ett steg framåt” 15
4.7 Sammanfattning 15
5. Human-in-the-loop som designprincip 16
5.1 Inledning 16
5.2 Från automation till beslutsstöd 16
5.3 Varför mänsklig bedömning inte kan elimineras 17
5.4 Human-in-the-loop som arkitektur, inte funktion 17
5.5 Risk, ansvar och legitimitet 18
5.6 Implikationer för mailbot-design 18
5.7 Sammanfattning 19
6. Mailbot-arkitekturen: teknisk och funktionell genomlysning 19
6.1 Inledning 19
6.2 Arkitekturens grundantaganden 19

6.3 Funktionell uppdelning: analys, bedömning, förslag 20
6.3.1 Analys: vad handlar mailet om? 20
6.3.2 Bedömning: hur riskfyllt är ärendet? 20
6.3.3 Förslag: generativt, men inte auktoritativt 21
6.4 Human-in-the-loop i praktiken 21
6.5 Var språkmodellen inte används 21
6.6 Sammanfattning 22
7. Study case: mailbot i golfklubbskontext 22
7.1 Inledning och avgränsning 22
7.2 Typologi av inkommande email 22
7.3 Mailbotens analysfas i praktiken 23
7.4 Riskbedömning och eskalering 23
7.5 Generering av svarsförslag i låg- och medelriskärenden 24
7.6 Arbetsflöde och kognitiv belastning 24
7.7 Ackumulering av organisatorisk kunskap 24
7.8 Sammanfattning 25
8. Systematisk jämförelse av alternativa lösningar och deras konsekvenser 25
8.1 Inledning: varför jämförelsen måste tas på allvar 25
8.2 Analysram: vilka dimensioner är relevanta? 25
8.3 Alternativ A: Egen LLM-server och intern chatbot 26
8.3.1 Vad lösningen lovar 26
8.3.2 Teknisk realitet: modell, infrastruktur och drift 26
8.3.3 Organisatoriska konsekvenser: falsk autonomi 27
8.3.4 Empiriska lärdomar: lyckade och misslyckade exempel 27
8.4 Alternativ B: Extern chatbot-tjänst för golfklubbar 28
8.4.1 Standardiseringens pris 28
8.4.2 Second-order effects 28
8.5 Alternativ C: Manuell användning av ChatGPT eller Claude 28
8.5.1 Individuell effektivitet vs organisatorisk effektivitet 28
8.5.2 Prompt-bördan som dold kostnad 28
8.6 Alternativ D: Integrerad AI i e-postklienter 29
8.6.1 Begränsad beslutsförmåga 29
8.7 Alternativ E: Human-in-the-loop mailbot 29
8.7.1 Sammanvägd analys 29
8.8 Sammanfattning 29

9. Second-order effects och failure amplification 29
9.1 Inledning: bortom förstahandsnytta 29
9.2 Vad menas med second-order effects? 30
9.3 Failure amplification: när små fel blir stora problem 30
9.4 Auktoritet och språklig övertygelse 31
9.5 Förväntningsglidning över tid 31
9.6 Belastningsförskjutning snarare än belastningsminskning 31
9.7 Varför human-in-the-loop dämpar second-order effects 32
9.8 Sammanfattning 32
10. Organisatoriskt lärande och institutionellt minne 32
10.1 Inledning: från effektivisering till kapacitetsuppbyggnad 32
10.2 Individuell intelligens vs institutionell intelligens 33
10.3 Varför många AI-lösningar inte ger organisatoriskt lärande 33
10.3.1 Brist på struktur 33
10.3.2 Avsaknad av feedbackloopar 33
10.3.3 Överfokus på output 34
10.4 Mailboten som lärande artefakt 34
10.5 Institutionellt minne i praktiken 34
10.6 Konsekvenser för styrning och utveckling 35
10.7 Sammanfattning 35
11. Styrning, ansvar och governance 35
11.1 Inledning: varför governance inte är ett tillägg 35
11.2 Ansvar kan inte delegeras bort 35
11.3 Governance-utmaningar i generativa AI-system 36
11.4 Mailbot-arkitekturen som governance-vänlig design 36
11.4.1 Tydlig separering av roller 36
11.4.2 Mänsklig avsändare och legitimt beslutsfattande 37
11.5 Spårbarhet, transparens och revision 37
11.6 Governance över tid: från kontroll till styrning 37
11.7 Sammanfattning 38
12. Införandestrategi 38
12.1 Inledning: varför införandet är ett systemproblem 38
12.2 Börja där risken är lägst, inte där vinsten ser störst ut 38
12.3 Tydliggör vad systemet inte ska göra 39
12.4 Intern användning före extern exponering 39

12.5 Utbildning som kalibrering, inte som träning 39
12.6 Mät rätt saker från början 40
12.7 Iterativ justering och kontrollerad expansion 40
12.8 Sammanfattning 40
13. Avslutande syntes och slutsats 41
13.1 Från teknikval till designval 41
13.2 Varför ambition ofta missriktas 41
13.3 Human-in-the-loop som rationell slutpunkt, inte mellanläge 41
13.4 Mailboten som organisatorisk infrastruktur 42
13.5 Konservatism som designprincip 42
13.6 Slutsats 42
Referenser 43
Footnotes ..... **Error! Bookmark not defined.**
Tables ..... **Error! Bookmark not defined.**
Figures ..... **Error! Bookmark not defined.**

Sammanfattning

Detta ”technical white paper” analyserar införandet av AI-stöd i emailbaserad servicekommunikation, med särskilt fokus på golfklubbar som representanter för en bredare klass av medlemsbaserade serviceorganisationer. Utgångspunkten är att många AI-initiativ misslyckas inte på grund av bristande modellkapacitet, utan på grund av felaktig placering av tekniken i organisationens sociotekniska struktur.

Analysen visar att email i dessa organisationer fungerar som mer än ett kommunikationsmedel. Det är en beslutsyta där ansvar, förväntningar och organisatorisk praxis etableras och reproduceras. Detta gör email till en högriskdomän för helautomatisering, särskilt när generativa AI-system används för att producera svar som uppfattas som auktoritativa.

Rapporten argumenterar för att human-in-the-loop bör förstås som en stabil designprincip snarare än som ett tillfälligt kompromissläge. Med stöd i etablerad forskning om beslutsstödssystem, sociotekniska system, automation bias och organisatoriskt lärande visas hur en human-in-the-loop mailbot kan utnyttja språkmodellers styrkor utan att exponera organisationen för de second-order effects som ofta följer av chatbot-baserade lösningar.

Dokumentet presenterar en arkitektur för en sådan mailbot, analyserar alternativa lösningar såsom egen LLM-drift, externa chatbot-tjänster och manuellt AI-stöd, samt diskuterar införandestrategi, styrning och långsiktig organisatorisk påverkan. Slutsatsen är att en återhållsam, riskmedveten och governance-vänlig AI-arkitektur inte representerar en lägre ambitionsnivå, utan ett mer moget och hållbart teknikval.
Keywords: [Tap here to add keywords.]

1. Bakgrund och motiv

1.1 AI i serviceorganisationer: ett förskjutet problem

Under de senaste åren har generativa språkmodeller fått ett genomslag som få andra teknologier i modern tid. För många organisationer har detta skapat ett tryck att snabbt identifiera användningsområden, ofta med fokus på kund- och medlemskommunikation. Chatbotar, automatiserade svar och intern AI-assistans framstår som naturliga tillämpningar.

Samtidigt visar både forskning och praktisk erfarenhet att just dessa tillämpningar är förknippade med betydande risker. Servicekommunikation kännetecknas av tolkningsberoende, ansvarsbärande och relationella konsekvenser. Fel i detta sammanhang är sällan lokala; de tenderar att sprida sig genom organisationen i form av missnöje, merarbete och förtroendeförlust.

Mot denna bakgrund finns ett behov av mer nykter analys. Detta dokument är ett försök att bidra med en sådan analys, där fokus ligger på **var AI bör användas, var den inte bör användas, och hur tekniken kan integreras utan att undergräva organisatorisk stabilitet**.

1.2 Varför golfklubbar är en relevant studiearena

Golfklubbar utgör en intressant och ofta underskattad studiearena för AI i serviceorganisationer. De kombinerar flera egenskaper som gör dem representativa för en större klass av organisationer:

- medlemskap snarare än kundrelationer
- stark lokal praxis vid sidan av formella regelverk
- hög andel återkommande, men kontextkänsliga, serviceärenden
- begränsade administrativa resurser

I många klubbar hanteras en betydande del av den dagliga verksamheten via email: bokningar, dispenser, medlemsfrågor, klagomål, tävlingsadministration och ekonomiska ärenden. Samtidigt är toleransen för fel ofta låg, eftersom svar uppfattas som bindande besked från organisationen.

Detta gör golfklubbar till ett lämpligt sammanhang för att studera **hur AI-stöd kan införas utan att skapa mer problem än det löser**. Resonemangen i detta dokument är dock avsiktligt formulerade så att de är överförbara till andra serviceorganisationer med liknande egenskaper.

2. Syfte, avgränsning och angreppssätt

2.1 Syfte

Syftet med denna rapport är trefaldigt:

1. Att analysera email som en socioteknisk beslutsyta i serviceorganisationer.
2. Att utvärdera olika AI-baserade lösningar för emailhantering utifrån tekniska, organisatoriska och styrningsmässiga perspektiv.
3. Att formulera och motivera en arkitektur för en human-in-the-loop mailbot som ett rationellt förstaval i denna kontext.

Dokumentet är normativt i den meningen att det tydligt tar ställning för vissa designprinciper. Dessa ställningstaganden är dock konsekvent motiverade genom teknisk analys, forskningsanknytning och organisatorisk logik.

2.2 Avgränsning

Detta dokument gör flera medvetna avgränsningar. Det behandlar inte:

- detaljerad implementation eller kod
- jämförelser mellan specifika kommersiella LLM-modeller
- juridisk analys av dataskydd eller arbetsrätt i detalj

Fokus ligger i stället på **arkitektur, designprinciper och organisatoriska konsekvenser**. Detta val är gjort för att resonemangen ska förbli giltiga även när tekniklandskapet förändras.

2.3 Angreppssätt

Angreppssättet i dokumentet är analytiskt och syntetiserande snarare än empiriskt i snäv mening. Resonemangen bygger på:

- etablerad forskning inom sociotekniska system, beslutsstöd och AI-styrning
- rapporterade erfarenheter från både lyckade och misslyckade AI-implementationer
- ett tekniskt study case som illustrerar hur en mailbot-arkitektur fungerar i praktiken

Ambitionen är inte att presentera universella lösningar, utan att **klargöra vilka val som är rationella givet vissa organisatoriska förutsättningar**.

3. Email som organisatoriskt nervsystem

3.1 Inledning

I många organisationer betraktas email fortfarande som ett sekundärt kommunikationsmedium, ett arv från en tidigare teknisk era, gradvis ersatt av chattverktyg, portaler och appar. I praktiken fungerar email dock i stora delar av serviceorganisationer som ett organisatoriskt nervsystem: det är genom email som förfrågningar initieras, beslut kommuniceras, ansvar tillskrivs och relationer upprätthålls.

Detta gäller i synnerhet organisationer med en kombination av medlemskap, tjänsteleverans och lokal praxis, där kommunikationen sällan kan reduceras till standardiserade formulär eller strikt definierade arbetsflöden. Golfklubbar är ett tydligt exempel, men resonemangen i detta kapitel är avsiktligt generella och gäller en bred klass av serviceorganisationer.

Utgångspunkten för detta white paper är att **email inte primärt är ett informationsbärande medium, utan en besluts- och åtagandeyta**. Detta faktum får direkta konsekvenser för hur och var AI-baserad automation kan införas utan att skapa systemisk risk.

3.2 Email som beslutsyta snarare än informationskanal

I teorin kan email beskrivas som ett asynkront textbaserat kommunikationsmedium. I praktiken fungerar email i organisationer ofta som:

- startpunkt för ärenden
- bärare av implicita löften
- dokumentation av tolkningar och undantag, samt
- bevismaterial vid senare oenighet.

Detta är väldokumenterat inom forskning om organisatorisk kommunikation och sociotekniska system, där man länge har pekat på att tekniska kommunikationsmedel får sin faktiska funktion först i samspel med organisatoriska normer, ansvarsfördelning och maktstrukturer (Orlikowski, 1992; Suchman, 1987).

Ett centralt kännetecken för email är att **det skrivna svaret ofta uppfattas som mer bindande än avsändaren avsett**. Ett svar som är tänkt som preliminärt, informellt eller situationsberoende kan av mottagaren uppfattas som ett beslut eller ett löfte. Detta gäller särskilt när svaret kommer från en officiell adress eller funktion.

Ur ett systemperspektiv innebär detta att varje genererat mailsvar potentiellt:

- etablerar förväntningar
- skapar prejudikat
- påverkar framtida arbetsbelastning.

” Email är inte bara text!

Ett email är sällan bara ett svar på en fråga.
Email är ofta ett implicit ställningstagande,
även när avsändaren inte avsett det som sådant.”

3.3 Asynkronicitet, tolkning och risk

Email är asynkront. Detta är både dess styrka och dess risk.

Asynkronicitet innebär att avsändare och mottagare inte delar kontext i realtid. Tonfall, osäkerhet, tvekan och villkor måste uttryckas explicit i text för att inte gå förlorade. Forskning inom Computer-Supported Cooperative Work (CSCW) och Human–Computer Interaction (HCI) har visat att detta ökar risken för feltolkning, särskilt i situationer där:

- mottagaren saknar full kontext
- frågan rör undantag snarare än regel
- svaret innehåller implicita antaganden

I serviceorganisationer är dessa situationer inte undantag utan snarare norm.

När automation introduceras i ett sådant medium förstärks denna risk. Ett automatiserat eller AI-genererat svar saknar inte bara mänsklig intuition, utan också den sociala förmågan att markera osäkerhet på ett sätt som mottagaren intuitivt uppfattar som just osäkerhet. Språkmodeller tenderar dessutom, av design, att producera välformulerade och självsäkra svar, även när den underliggande tolkningen är osäker.

Detta skapar en asymmetri: **ju mer välformulerat ett felaktigt svar är, desto större är risken att det tas för sant**. Detta fenomen har i forskningen beskrivits som *algorithmic authority* och *automation bias* (Lee & See, 2004; Parasuraman & Riley, 1997).

3.4 Email som bärare av organisatorisk praxis

En ofta förbisedd aspekt av email är dess roll som bärare av lokal praxis. Till skillnad från formella regelverk och policydokument innehåller emailkommunikation:

- tolkningar av regler
- pragmatiska undantag
- situationsanpassade beslut

Detta innebär att emailhistoriken i en organisation ofta innehåller mer faktisk kunskap om hur organisationen fungerar än dess formella styrdokument. Samtidigt är denna kunskap fragmenterad, personbunden och sällan explicitgjord.

Ur ett designperspektiv är detta centralt: automation som ignorerar denna dimension riskerar att vara formellt korrekt men praktiskt felaktig.

”Formell korrekthet vs praktisk korrekthet
I många serviceorganisationer är den formellt korrekta lösningen ofta den praktiskt sämsta. Email är platsen där denna spänning hanteras i praktiken.”

3.5 Konsekvenser för AI-stödd automation

Utifrån ovanstående kan flera designimplikationer härledas:

1. **Email är en hög-risk-yta för helautomatisering.**
   Fel får konsekvenser som sträcker sig bortom det enskilda svaret.
2. **Exponerade AI-svar etablerar förväntningar.**
   Även ett preliminärt eller ungefärligt svar riskerar att bli normerande.
3. **”Nästan rätt” är ofta värre än ”inte alls”.**
   Ett felaktigt men självsäkert svar skapar merarbete än ett uteblivet svar.
4. **Automation måste kunna avstå.**
   Ett system som inte kan indikera osäkerhet eller eskalera till mänsklig bedömning är olämpligt i denna kontext.

Dessa implikationer pekar sammantaget mot att AI i emailflöden bör användas som **beslutsstöd**, inte som beslutsfattare. Detta är inte en teknisk begränsning i snäv mening, utan en konsekvens av hur email fungerar som socioteknisk system.

3.6 Sammanfattning

I detta kapitel har vi argumenterat för att email i serviceorganisationer bör förstås som ett organisatoriskt nervsystem snarare än ett neutralt kommunikationsmedium. Denna förståelse är avgörande för alla vidare resonemang om AI-stödd automation.

Den centrala slutsatsen är att email, just på grund av sin roll i beslut, ansvar och relationer, kräver **återhållsam och riskmedveten design**. Detta utgör den analytiska grunden för det human-in-the-loop-angreppssätt som utvecklas i efterföljande kapitel.

4. AI i serviceorganisationer: etablerade felslut

4.1 Inledning: varför felsluten upprepar sig

Trots ett växande forskningsunderlag och en snabbt växande mängd praktiska erfarenheter upprepar sig ett antal grundläggande felslut i organisationers användning av AI i service- och kommunikationsintensiva verksamheter. Dessa felslut är inte i första hand tekniska, utan kognitiva och organisatoriska. Gemensamt för dem är att de:

- förenklar relationen mellan teknik och nytta
- underskattar hur arbete faktiskt utförs i praktiken
- överskattar teknikens förmåga att ersätta snarare än stödja mänskligt omdöme

I detta avsnitt identifieras och analyseras ett antal sådana felslut som är särskilt relevanta för emailbaserad servicekommunikation. Avsikten är inte att peka ut enskilda aktörer, utan att klargöra varför vissa argument återkommer trots att de gång på gång visat sig vara svagt grundade.

4.2 Felslut 1: ”AI sparar alltid tid”

Ett av de vanligaste argumenten för att införa AI i serviceorganisationer är att tekniken förväntas spara tid. Antagandet är ofta linjärt: om ett system kan generera svar snabbare än en människa, kommer den totala arbetsbelastningen att minska.

Forskning och praktik visar att detta antagande är förenklat. I många fall ersätter AI inte arbete, utan **omformar det**. Särskilt i kommunikationsintensiva domäner leder automation ofta till:

- färre enkla ärenden, men fler komplexa efterärenden
- ökad tid per ärende när fel behöver redas ut
- mer emotionellt arbete i samband med missnöje och konflikter

Detta fenomen har dokumenterats i studier av automatiserad kundtjänst, där införandet av chatbotar ofta leder till ökad belastning på mänskliga handläggare i de ärenden som återstår, snarare än till minskad total arbetsbörda.

Ur ett systemperspektiv är detta inte förvånande. När AI tar hand om det enkla återstår det svåra, och det svåra är ofta oproportionerligt tidskrävande.

“Tidsbesparing är inte additiv

Att automatisera 80 procent av ärendena betyder inte att 80 procent av arbetet försvinner. Ofta betyder det att de återstående 20 procenten blir både tyngre och mer tidskrävande.”

4.3 Felslut 2: ”Chat är ett bättre gränssnitt än email”

Ett annat vanligt antagande är att chatbaserade gränssnitt är mer ”naturliga” och därmed bättre lämpade för servicekommunikation än email. Detta leder ofta till slutsatsen att chatbotar är ett naturligt förstaval.

Detta resonemang förbiser flera centrala aspekter:

- **Asynkronitet är inte ett problem i sig.**
  I många serviceärenden är det en fördel att kommunikation sker asynkront, eftersom det ger utrymme för eftertanke, samordning och dokumentation.
- **Email fungerar som arkiv och referens.**
  Svar i email uppfattas ofta som mer bindande just därför att de är spårbara och kan återkommas till.
- **Chat förstärker illusionen av omedelbarhet.**
  Detta kan höja förväntningarna på snabba och definitiva svar, även när ärendet kräver tolkning eller samråd.

Studier av chatbotar i kundservice visar att användare ofta uppskattar chatgränssnitt initialt, men att nöjdheten snabbt sjunker när systemet inte kan hantera gränsfall eller undantag. I sådana situationer upplevs chat som mer frustrerande än långsammare, men mer genomtänkta, kanaler.

4.4 Felslut 3: ”Bättre formulering ger bättre svar”

Generativa språkmodeller är exceptionellt bra på att producera välformulerad text. Detta leder ibland till slutsatsen att ett mer välformulerat svar också är ett bättre svar. I servicekommunikation är detta ett farligt antagande!

Ett välformulerat svar kan:

- maskera osäkerhet
- dölja villkor och undantag
- förstärka intrycket av auktoritet

Forskning om *automation bias* och *algorithmic authority* visar att människor tenderar att övervärdera svar som uttrycks med språklig säkerhet, särskilt när de kommer från ett system som uppfattas som neutralt eller tekniskt avancerat.

I praktiken innebär detta att språklig kvalitet kan fungera som en **förstärkare av fel**, snarare än som en garanti för korrekthet.

“Språklig kvalitet är inte epistemisk kvalitet

Ett svar kan vara perfekt formulerat och samtidigt praktiskt felaktigt.”

4.5 Felslut 4: ”Mer data och bättre modeller löser problemen”

Ett fjärde felslut är tron att de problem som observeras i AI-baserad servicekommunikation huvudsakligen beror på otillräcklig modellkapacitet. Följaktligen antas att större modeller, mer data eller bättre finjustering kommer att eliminera riskerna.

Detta resonemang missar en central poäng: **många av problemen är strukturella, inte statistiska**.

Frågor om:

- ansvar
- legitimitet
- konsekvens
- förväntningar

kan inte lösas genom bättre prediktion ensam. De kräver arkitektoniska och organisatoriska beslut om var och hur tekniken ska användas.

Forskning om säkerhetskritiska system har länge visat att förbättrad komponentprestanda inte nödvändigtvis leder till förbättrad systemprestanda, särskilt i komplexa sociotekniska miljöer.

4.6 Felslut 5: ”Automation är alltid ett steg framåt”

Ett mer subtilt felslut är den normativa föreställningen att automation per definition representerar framsteg. I denna logik blir varje steg bort från mänsklig inblandning ett tecken på teknisk mognad.

Historiskt sett är detta påstående svagt underbyggt. Studier av automatisering i flyg, sjukvård och industri visar att överautomation ofta leder till:

- minskad situationsmedvetenhet
- sämre förmåga att hantera avvikelser
- ökad sårbarhet vid systemfel

I servicekommunikation innebär detta att ett system som ”klarar sig självt” i normallägen kan vara sämre rustat för de situationer där organisationens omdöme faktiskt prövas.

”Mognad är att veta när man inte ska automatisera

Ett moget system är inte det som automatiserar mest,
utan det som automatiserar rätt saker.”

4.7 Sammanfattning

De felslut som analyserats i detta avsnitt är inte resultatet av okunskap, utan ofta av förenklade mentala modeller för hur teknik skapar nytta i organisationer. Gemensamt för dem är att de underskattar den roll som ansvar, tolkning och förväntningar spelar i servicekommunikation.

Den centrala slutsatsen är att **AI i serviceorganisationer inte misslyckas främst därför att tekniken är otillräcklig, utan därför att den används på fel plats, med fel grad av autonomi och med fel antaganden om arbete och ansvar**.

Detta skapar en tydlig övergång till de följande avsnitten, där fokus ligger på hur en human-in-the-loop mailbot explicit adresserar dessa felslut genom arkitektur, snarare än genom löften om bättre modeller eller snabbare svar.

5. Human-in-the-loop som designprincip

5.1 Inledning

Begreppet *human-in-the-loop* (HITL) används ofta slentrianmässigt i diskussioner om AI-system, ibland som en tillfällig försäkring, ibland som en efterhandskonstruktion när helautomatisering visat sig problematisk. I detta kapitel argumenteras för en mer stringent position: **human-in-the-loop är i många organisatoriska sammanhang inte en kompromiss, utan en nödvändig designprincip**.

Utgångspunkten är att vissa domäner präglas av sådan grad av tolkningsberoende, konsekvenskänslighet och ansvarsbärande att helautomatisering, även med tekniskt avancerade modeller, introducerar systemiska risker som inte kan reduceras genom förbättrad modellprestanda ensam. Emailhantering i serviceorganisationer utgör ett sådant domänområde.

Syftet med kapitlet är att:

- klargöra vad human-in-the-loop innebär i praktiken, bortom slagord
- visa hur HITL är förankrat i etablerad forskning om beslutsstöd och säkerhetskritiska system
- positionera HITL som ett medvetet arkitekturval snarare än ett tekniskt nödläge

5.2 Från automation till beslutsstöd

En central distinktion i litteraturen om intelligenta system är skillnaden mellan **automation** och **decision support**. Automation syftar till att ersätta mänskligt arbete genom att låta systemet utföra uppgifter autonomt. Beslutsstödssystem (Decision Support Systems, DSS) syftar i stället till att förbättra kvaliteten i mänskliga beslut genom analys, strukturering och presentation av relevant information.

Redan i tidiga DSS-ramverk (Simon, 1960; Sprague & Carlson, 1982) betonas att vissa beslut inte bör automatiseras fullt ut, särskilt när:

- målen är delvis motstridiga
- kriterierna är ofullständigt specificerade

- konsekvenserna sträcker sig bortom det omedelbara problemet

Emailbaserade serviceärenden uppfyller ofta samtliga dessa kriterier. Frågan är sällan enbart *vad* som är korrekt enligt regelverk, utan *hur* ett svar påverkar relationer, framtida förväntningar och arbetsbelastning.

I detta ljus bör AI-stöd i emailflöden förstås som ett **beslutsstödssystem med generativ komponent**, inte som ett autonomt svarssystem.

Call-out: ”Automation är inte ett självändamål

Att ersätta mänskliga beslut är inte per definition ett framsteg.
I många sammanhang är det mer rationellt att förstärka
mänskligt omdöme än att kringgå det.

5.3 Varför mänsklig bedömning inte kan elimineras

Ett återkommande argument för ökad automation är att språkmodeller snabbt förbättras och närmar sig, eller i vissa avseenden överträffar, mänsklig prestation. Detta är i grunden korrekt i snäva uppgifter som mönsterigenkänning eller textproduktion. Det missar dock en avgörande aspekt: **problemet är inte främst modellernas språkliga förmåga, utan domänens karaktär**.

Mänsklig bedömning behövs inte därför att AI är ”för dum”, utan därför att:

- beslut ofta kräver avvägningar mellan formell korrekthet och praktisk rimlighet
- undantag är regel snarare än avvikelse
- ansvar inte kan delegeras bort utan att samtidigt förlora legitimitet

Forskning om *automation bias* visar dessutom att människor tenderar att överlita sig på automatiserade system, särskilt när dessa uppfattas som tekniskt sofistikerade eller neutrala (Parasuraman & Riley, 1997; Dzindolet et al., 2003). Detta innebär att ett system som ibland har fel men alltid ger svar riskerar att minska, snarare än öka, den totala kvaliteten i beslutsfattandet.

Ur ett designperspektiv är detta kritiskt: **ett system som reducerar mänsklig vaksamhet utan att kunna ta fullt ansvar är sämre än inget system alls**!

5.4 Human-in-the-loop som arkitektur, inte funktion

I många implementationer behandlas HITL som en funktionell detalj: ett godkännandeklick, en fallback-mekanism eller en manuell override. I detta white paper används begreppet i en striktare bemärkelse.

Human-in-the-loop förstås här som en **arkitektonisk princip** där:

- systemet explicit är designat för att inte fatta slutgiltiga beslut
- mänsklig bedömning är en integrerad del av flödet, inte ett undantag
- systemets output är formulerad som förslag, inte svar

Detta innebär bland annat att:

- osäkerhet ska kunna representeras och kommuniceras

- systemet ska kunna avstå från att föreslå svar när risknivån är hög
- mänsklig interaktion inte ska upplevas som ett misslyckande, utan som normalläge

Denna syn ligger nära forskning om *mixed-initiative systems*, där människa och system samverkar dynamiskt beroende på kontext och risknivå (Horvitz, 1999).

Call-out: Ett system som alltid svarar är ett system som inte vet när det ska stanna

Förmågan att avstå är inte en begränsning i intelligenta system, utan ett tecken på mognad.

5.5 Risk, ansvar och legitimitet

En aspekt som ofta underbetonas i tekniska diskussioner är **ansvarsfrågan**. I serviceorganisationer är det inte tillräckligt att ett svar är tekniskt korrekt; det måste också vara legitimt. Legitimitet uppstår när mottagaren upplever att:

- beslutet är rimligt
- avsändaren kan stå för det
- det finns en ansvarsbärande instans

Helautomatiserade AI-svar riskerar att underminera denna legitimitet, särskilt när de hanterar gränsfall eller undantag. Även om organisationen formellt tar ansvar för AI-systemets svar, uppfattas ansvaret ofta som diffust i praktiken.

Human-in-the-loop-design adresserar detta genom att:

- tydliggöra var beslut fattas
- behålla mänsklig avsändare i kritiska kommunikationspunkter
- möjliggöra spårbarhet mellan förslag, beslut och utfall

Ur ett styrnings- och governance-perspektiv är detta inte en detaljfråga, utan en grundförutsättning för hållbar användning av AI i organisatoriska kärnprocesser.

5.6 Implikationer för mailbot-design

Applicerat på emailhantering leder detta till flera konkreta designimplikationer:

1. **AI ska analysera och strukturera, inte avsluta ärenden.**
   Klassificering, intentionsanalys och förslag är lämpliga uppgifter.
2. **Beslutspunkten ska vara mänsklig.**
   Det är där ansvar, omdöme och legitimitet möts.
3. **Systemet ska stödja, inte pressa, användaren.**
   Ett bra HITL-system reducerar kognitiv belastning snarare än att addera ett nytt granskningssteg.
4. **Osäkerhet ska vara synlig.**
   Ett system som maskerar osäkerhet bakom välformulerad text är olämpligt i denna kontext.

Dessa principer utgör den konceptuella grunden för den mailbot-arkitektur som analyseras i efterföljande kapitel.

5.7 Sammanfattning

I detta kapitel har vi argumenterat för att human-in-the-loop inte bör förstås som en teknisk kompromiss, utan som ett medvetet designval i domäner där beslut är kontextberoende, ansvarsbärande och relationspåverkande.

För emailbaserad servicekommunikation innebär detta att AI bör användas som ett beslutsstöd som:

- förstärker mänskligt omdöme
- reducerar repetitiv belastning
- utan att underminera ansvar, legitimitet eller organisatorisk kontroll

Denna position utgör den teoretiska och tekniska bryggan mellan problemanalysen i kapitel 3 och den konkreta systemarkitektur som presenteras i nästa avsnitt.

6. Mailbot-arkitekturen: teknisk och funktionell genomlysning

6.1 Inledning

De föregående avsnitten har etablerat två centrala utgångspunkter:
för det första att email i serviceorganisationer utgör en hög-risk-yta för ogenomtänkt automation, och för det andra att *human-in-the-loop* bör betraktas som en designprincip snarare än en teknisk kompromiss.

I detta avsnitt konkretiseras dessa insikter i form av en **mailbot-arkitektur**. Fokus ligger inte på implementation i snäv mening, utan på hur arkitektoniska val kan realisera human-in-the-loop i praktiken och samtidigt utnyttja moderna språkmodellers styrkor utan att exponera deras svagheter.

Utgångspunkten är att arkitekturen ska:

- vara begriplig för tekniskt kunniga beslutsfattare
- vara möjlig att revidera och styra över tid
- göra ansvarsfördelning och begränsningar explicita

6.2 Arkitekturens grundantaganden

Mailbot-arkitekturen vilar på ett antal explicita antaganden. Dessa är inte neutrala, utan uttrycker medvetna designval.

1. **Alla inkommande mail är inte lika.**
   Vissa är triviala, andra komplexa, några riskfyllda.
2. **Språkmodeller är bra på text, sämre på konsekvensbedömning.**
   De kan formulera förslag, men bör inte avgöra när ett svar är legitimt.
3. **Risk är kontextuell, inte absolut.**
   Samma fråga kan vara låg risk i ett sammanhang och hög risk i ett annat.
4. **Systemet ska vara deterministiskt där det måste, probabilistiskt där det kan.**

Detta är en klassisk princip i säkerhetskritiska sociotekniska system.

Dessa antaganden ligger i linje med både äldre DSS-litteratur och modern forskning om *human-centered AI* (Amershi et al., 2019; Shneiderman, 2020).

6.3 Funktionell uppdelning: analys, bedömning, förslag

En central arkitektonisk princip är **funktionell separation**. Mailboten delas upp i tre logiska steg som hålls så oberoende som möjligt:

1. **Analys**
2. **Bedömning**
3. **Förslag**

Denna uppdelning är avsiktlig och syftar till att undvika att generativa komponenter får implicit beslutsmakt.

6.3.1 Analys: vad handlar mailet om?

I analyssteget bearbetas inkommande mail för att extrahera strukturell information, exempelvis:

- ärendetyp
- avsändarkategori
- identifierbara objekt (datum, bokningar, personer)
- språkliga signaler på osäkerhet, konflikt eller frustration

Detta steg kan delvis använda språkmodeller, men är i första hand **beskrivande**, inte normativt. Målet är inte att avgöra *vad som ska göras*, utan att skapa ett strukturerat underlag.

I DSS-termer motsvarar detta *intelligence phase* (Simon, 1960).

6.3.2 Bedömning: hur riskfyllt är ärendet?

I bedömningssteget sker det som arkitektoniskt är mest avgörande: **riskklassificering**. Här bedöms bland annat:

- om ärendet rör policy, undantag eller tolkning
- om ett felaktigt svar kan få juridiska eller relationella konsekvenser
- om ärendet bör eskaleras direkt till mänsklig handläggning

Detta steg bör i huvudsak vara **regelbaserat och deterministiskt**, just för att säkerställa spårbarhet och förutsägbarhet. Språkmodeller kan användas som stöd, men inte som ensam beslutsinstans.

Denna design hållning är väl förankrad i forskning om *risk-aware AI* och *human-AI collaboration*, där man betonar vikten av explicita kontrollpunkter i system med potentiellt höga konsekvenser (Rahwan et al., 2019; Amodei et al., 2016).

”Där risken är hög måste systemet vara tråkigt

I riskfyllda delar av ett system är förutsägbarhet
ofta viktigare än sofistikation.”

6.3.3 Förslag: generativt, men inte auktoritativt

Först i detta tredje steg används språkmodeller i sin mest synliga roll: att generera textförslag. Avgörande är dock att:

- texten presenteras som *förslag*
- kontext och bedömning följer med
- systemet inte maskerar osäkerhet genom språklig elegans

Här utnyttjas språkmodellernas styrka, formulering, tonanpassning, sammanhang, samtidigt som deras begränsningar hanteras genom arkitekturen snarare än genom promptar.

Detta ligger nära principer som i modern litteratur beskrivs som *bounded autonomy* och *scaffolded intelligence* (Shneiderman, 2020).

6.4 Human-in-the-loop i praktiken

Human-in-the-loop realiseras i arkitekturen inte genom ett enskilt godkännandeklick, utan genom att:

- systemet **inte kan avsluta ett ärende själv**
- människan alltid möter ett strukturerat beslutsunderlag
- ansvar och avsändarskap förblir mänskliga

Ett centralt designmål är att **inte skapa ett extra granskningsarbete**, utan snarare att minska den kognitiva belastningen genom att:

- reducera variation i svarsförslag
- göra risk och osäkerhet explicit
- samla relevant kontext på ett ställe

Forskning om kognitiv belastning och arbetsflödesstöd visar att detta är avgörande för att beslutsstödssystem faktiskt ska användas, snarare än kringgås (Norman, 2013; Endsley, 2017).

6.5 Var språkmodellen inte används

En lika viktig del av arkitekturen är var språkmodellen **inte** används. Den används inte för att:

- fatta beslut om utskick
- avgöra policyfrågor
- klassificera hög-risk-ärenden utan deterministiskt stöd

Detta är ett medvetet avsteg från många kommersiella chatbot-lösningar, där språkmodellen ofta får bära både analys, bedömning och svar i ett sammanhållet steg.

Arkitekturvalet speglar insikten att **modellernas största svaghet inte är att de ibland har fel, utan att de är dåliga på att veta när de har fel**.

”Begränsning som styrka

Att begränsa en komponent är inte ett
misslyckande, utan ett sätt att placera den
där den gör mest nytta och minst skada.”

6.6 Sammanfattning

I detta avsnitt har mailbot-arkitekturen presenterats som ett sociotekniskt system där human-in-the-loop inte är ett tillägg, utan en bärande princip. Genom att separera analys, riskbedömning och generering av förslag kan systemet dra nytta av moderna språkmodeller utan att exponera organisationen för de risker som helautomatisering i emailflöden innebär.

Arkitekturen är medvetet konservativ i sina kontrollpunkter och generös i sitt beslutsstöd. Detta är inte en teknisk begränsning, utan ett uttryck för en designfilosofi där ansvar, legitimitet och långsiktig hållbarhet prioriteras framför maximal automation.

7. Study case: mailbot i golfklubbskontext

7.1 Inledning och avgränsning

Detta avsnitt presenterar ett *study case* som konkretiserar den mailbot-arkitektur som beskrivits tidigare, applicerad på en golfklubb som serviceorganisation. Avsikten är inte att redovisa en empirisk fallstudie i strikt metodologisk mening, utan att använda en realistisk och tekniskt konsistent kontext för att analysera hur arkitekturen fungerar, vilka beslutspunkter som uppstår och hur human-in-the-loop realiseras i praktiken.

Golfklubben används här som representant för en bredare klass av organisationer med följande kännetecken:

- medlemsbaserad struktur
- kombination av formella regler och lokal praxis
- hög andel återkommande men kontextkänsliga serviceärenden
- begränsade administrativa resurser

Resonemangen är därmed generaliserbara till andra serviceorganisationer med liknande egenskaper, exempelvis idrottsföreningar, kulturinstitutioner eller mindre medlemsdrivna organisationer.

7.2 Typologi av inkommande email

Ett första analytiskt steg är att förstå **vilken typ av ärenden** som faktiskt inkommer via email. I praktiken kan dessa grovt delas in i följande kategorier:

1. **Rutinärenden**
   Frågor med tydliga, ofta dokumenterade svar, exempelvis öppettider, greenfee, bokningsregler eller medlemskapets grundvillkor.
2. **Tolkningsärenden**

Frågor som rör hur regler tillämpas i ett specifikt sammanhang, exempelvis dispensfrågor, bokningsundantag eller kombinationer av olika villkor.

3. **Relationskänsliga ärenden**
   Ärenden där tonläge, formulering och timing är centrala, exempelvis klagomål, missnöje eller konflikter mellan medlemmar.
4. **Administrativt komplexa ärenden**
   Ärenden som kräver samordning mellan flera system eller roller, exempelvis fakturering, medlemsstatus eller tävlingsadministration.

Det centrala är att **endast en delmängd av dessa ärenden lämpar sig för långtgående automation**, medan andra kräver mänsklig bedömning även om de är frekventa.

”Frekvent betyder inte trivialt

Ett ärende kan förekomma ofta och ändå vara olämpligt för helautomatisering. Frekvens och risk är två oberoende dimensioner.”

7.3 Mailbotens analysfas i praktiken

När ett email anländer initierar mailboten sin analysfas. I study case-scenariot innebär detta att systemet extraherar och strukturerar information såsom:

- avsändartyp (medlem, gäst, extern part)
- referenser till bokningar, datum eller tävlingar
- språkliga indikatorer på osäkerhet, frustration eller kravställning
- historik från tidigare relaterade ärenden

Det är väsentligt att understryka att analysfasen **inte försöker förstå ärendet i normativ mening**, utan syftar till att skapa ett rikare beslutsunderlag för efterföljande steg.

I praktiken innebär detta att samma inkommande mail kan beskrivas längs flera dimensioner samtidigt, till exempel som både rutinärt och relationskänsligt. Denna mångdimensionella representation är central för senare riskbedömning.

7.4 Riskbedömning och eskalering

I nästa steg sker riskbedömningen. Här operationaliseras de principer som diskuterats i tidigare avsnitt. I study case-scenariot klassificeras risk längs flera axlar, exempelvis:

- **Policy-risk**: risk att svaret etablerar eller förändrar praxis
- **Relationsrisk**: risk att svaret påverkar medlemsrelationer negativt
- **Prejudikat-risk**: risk att svaret används som referens i framtida ärenden

Ett ärende som vid första anblicken verkar trivialt kan därmed bedömas som hög risk om det exempelvis rör ett undantag från en regel som ofta ifrågasätts. Vid hög risk:

- genereras inget färdigt svarsförslag
- ärendet markeras för manuell handläggning
- analysresultatet presenteras för handläggaren som beslutsstöd

Detta illustrerar en central poäng i arkitekturen: **systemets viktigaste funktion är inte att svara snabbt, utan att veta när det inte bör svara alls**!

”Eskalering är ett resultat, inte ett misslyckande

När ett system eskalerar ett ärende till mänsklig handläggning
har det ofta gjort exakt det som designats för.”

7.5 Generering av svarsförslag i låg- och medelriskärenden

För ärenden som bedöms som låg eller medel risk genererar mailboten ett eller flera svarsförslag. I study case-scenariot innebär detta att:

- språklig ton anpassas efter avsändartyp
- relevanta policyutdrag eller praxisreferenser inkluderas
- eventuella osäkerheter markeras explicit i texten

Handläggaren möter därmed inte ett ”färdigt svar”, utan ett strukturerat förslag som kan accepteras, modifieras eller förkastas. Detta reducerar både:

- variation mellan olika handläggares svar
- tiden för formulering
- risken för att viktig information utelämnas

Samtidigt förblir det slutliga beslutet, och därmed ansvaret, mänskligt.

7.6 Arbetsflöde och kognitiv belastning

Ett återkommande problem med många AI-stödda verktyg är att de introducerar nya arbetsmoment snarare än att integreras i befintliga flöden. I study case-scenariot är mailboten därför designad för att:

- presentera analys och förslag direkt i det befintliga emailverktyget
- undvika krav på externa promptar eller verktyg
- minska behovet av kontextväxling

Ur ett kognitivt perspektiv innebär detta att handläggaren i högre grad kan fokusera på bedömning snarare än informationsinsamling eller formulering. Detta är i linje med forskning om *cognitive offloading* och beslutsstöd, där nyttan av ett system ofta avgörs av hur väl det reducerar mental belastning snarare än hur sofistikerat det är tekniskt.

7.7 Ackumulering av organisatorisk kunskap

Över tid ackumulerar mailboten strukturerad information om:

- vilka typer av ärenden som är vanliga
- var osäkerhet och risk ofta uppstår
- vilka svar som återkommande modifieras av handläggare

I study case-scenariot används denna information inte för att automatisera bort människan, utan för att:

- identifiera otydliga policyområden

- förbättra mallar och beslutsstöd
- ge ledningen bättre insikt i faktisk verksamhet

Detta illustrerar hur mailboten fungerar som ett verktyg för **institutionellt lärande**, snarare än som en isolerad produktivitetsförstärkare.

7.8 Sammanfattning

Study case-avsnittet visar hur mailbot-arkitekturen kan tillämpas i en konkret servicekontext utan att frångå de principer som diskuterats tidigare. Genom att separera analys, riskbedömning och generering av svarsförslag, och genom att konsekvent hålla människa i loopen, kan systemet reducera administrativ belastning utan att introducera nya risker.

Den centrala observationen är att **värdet inte primärt ligger i snabbare svar**, **utan i mer konsekventa, spårbara och legitimt förankrade beslut** i den dagliga kommunikationen.

8. Systematisk jämförelse av alternativa lösningar och deras konsekvenser

8.1 Inledning: varför jämförelsen måste tas på allvar

I diskussioner om AI i organisationer reduceras valet av lösning ofta till en fråga om teknisk kapabilitet: vilken modell är bäst, vilken lösning är mest avancerad, vilken ger snabbast svar. Detta avsnitt tar en annan utgångspunkt.

Här betraktas varje alternativ som ett **socioteknisk system**, det vill säga som en kombination av teknik, människor, arbetsflöden, ansvar och långsiktiga konsekvenser. Fokus ligger inte enbart på *förstahandsnytta*, utan på **second-order effects**, det vill säga de effekter som uppstår när systemet väl är i drift och börjar påverka beteenden, förväntningar och arbetsformer.

Erfarenheter från både forskning och praktik visar att det är just dessa effekter som avgör om en AI-satsning blir hållbar eller problematisk (Susskind & Susskind, 2015; Bainbridge, 1983; Amershi et al., 2019).

8.2 Analysram: vilka dimensioner är relevanta?

För att undvika anekdotisk jämförelse används följande analysdimensioner genomgående:

1. **Funktionell räckvidd**
   Vad påstår sig lösningen kunna göra?
2. **Beslutsmakt**
   Vem eller vad fattar det slutliga beslutet?
3. **Riskexponering**
   Vad händer när systemet har fel?
4. **Organisatorisk belastning över tid**
   Minskar eller omfördelar lösningen arbete?
5. **Krav på kompetens och drift**

Vad krävs för att lösningen ska fungera i praktiken?

6. **Lärande och styrbarhet**
   Kan organisationen förstå, justera och förbättra systemet?

Dessa dimensioner återkommer i analysen av samtliga alternativ.

Dimension	**Egen LLM + chatbot**	**Extern chatbot-tjänst**	**Manuell ChatGPT/Claude**	**Integrerad mail-AI**	**Human-in-the-loop mailbot**
Primärt syfte	Direkt svar	Direkt svar	Individuell hjälp	Textförbättring	Beslutsstöd
Exponering mot användare	Direkt	Direkt	Indirekt	Direkt	**Ingen**
Slutligt beslutsfattande	AI	AI	Människa	AI	**Människa**
Risk vid fel	Mycket hög	Hög	Medel	Medel	**Låg**
Failure amplification	Hög	Hög	Medel	Medel	**Låg (dämpad)**
Krav på intern AI-kompetens	Mycket hög	Låg	Medel	Låg	**Medel (styrbar)**
Drift- och underhållskostnad	Hög	Medel	Låg	Låg	**Medel**
Konsistens över tid	Medel	Medel	Låg	Låg	**Hög**
Spårbarhet och revision	Låg	Låg	Mycket låg	Mycket låg	**Hög**
Organisatoriskt lärande	Låg	Låg	Ingen	Ingen	**Hög**
Governance-vänlighet	Låg	Låg	Mycket låg	Låg	**Hög**
Lämplighet som förstasteg	Låg	Låg	Låg	Låg	**Hög**

8.3 Alternativ A: Egen LLM-server och intern chatbot

8.3.1 Vad lösningen lovar

Att drifta en egen LLM, ofta i kombination med dokumentuppladdning och en chatbot, framstår vid första anblicken som attraktivt, då ansatsen har potentialen att man har:

- full kontroll över data
- möjlighet till lokal anpassning
- oberoende från externa leverantörer
- signal om teknisk framkant

Dvs, i teorin erbjuder detta maximal autonomi. I praktiken är bilden betydligt mer komplex.

8.3.2 Teknisk realitet: modell, infrastruktur och drift

Forskning och industrirapporter från de senaste åren visar att **egen LLM-drift är kvalitativt annorlunda än att konsumera en färdig molntjänst**.

Centrala utmaningar inkluderar:

- **Modellkvalitet**
  Mindre öppna modeller presterar genomgående betydligt sämre än state-of-the-art-modeller tränade med massiv datamängd och kontinuerlig RLHF (Brown et al., 2020; OpenAI, 2023).
- **Inference-kostnader och latens**
  Även relativt små modeller kräver betydande hårdvaruresurser för stabil drift (Patterson et al., 2021).
- **Kontinuerlig uppdatering**
  Modeller åldras snabbt. Utan kontinuerlig reträning eller finjustering degraderas prestandan i takt med förändrad verksamhet och språkbruk. Modellerna tenderar att öka i storlek vilket ofta innebär behov av mer krävande hårdvara.

Flera empiriska studier och industrirapporter pekar på att organisationer ofta **underskattar driftkomplexiteten med en faktor 5–10** jämfört med initial kalkyl (Narayanan et al., 2021).

8.3.3 Organisatoriska konsekvenser: falsk autonomi

Den kanske största risken är dock inte teknisk, utan organisatorisk. Interna chatbotar tenderar att:

- svara med hög språklig säkerhet
- sakna förståelse för lokala undantag
- etablera förväntningar hos användare

När svaren är lågkvalitativa men övertygande uppstår ett välkänt mönster:

1. Chatboten ger ett ungefärligt svar
2. Användaren agerar på svaret
3. Kansliet måste senare korrigera eller förklara
4. Arbetsbördan ökar, inte minskar

Detta fenomen har beskrivits i forskningen som *failure amplification* och *authority misalignment* (Bender et al., 2021; Elish, 2019).

”Egen drift betyder eget ansvar

Att drifta en egen LLM innebär inte bara teknisk kontroll,
utan att organisationen själv blir ansvarig för
modellens begränsningar, fel och konsekvenser.”

8.3.4 Empiriska lärdomar: lyckade och misslyckade exempel

Det finns lyckade exempel på intern LLM-användning, men de delar vissa kännetecken:

- extremt snäva domäner
- låg konsekvens vid fel
- stark intern AI-kompetens

Misslyckade exempel, vilket är vanligare i servicekontexter, kännetecknas av:

- överskattad modellförmåga

- underskattad driftkostnad
- avsaknad av human-in-the-loop
- otydligt ansvar

Särskilt i kund- och medlemskommunikation är misslyckanden väl dokumenterade (Liao et al., 2023; Mozilla Foundation, 2023).

8.4 Alternativ B: Extern chatbot-tjänst för golfklubbar

8.4.1 Standardiseringens pris

Extern chatbot-tjänst erbjuder skalfördelar, men till priset av standardisering. Forskning om plattformsbaserade tjänster visar att:

- lokala variationer ofta reduceras bort
- praxis ersätts av generiska regler
- ansvar förblir lokalt trots centraliserad logik

För medlemsorganisationer med stark lokal kultur skapar detta ofta friktion snarare än effektivitet.

8.4.2 Second-order effects

Studier av chatbotar i kundtjänst visar att (Derisci & Meyer, 2022; Følstad & Brandtzæg, 2017):

- felaktiga svar ökar återkontakt
- användare blir mer frustrerade när de först möter automation
- mänsklig service upplevs sämre efter chatbotinteraktion

8.5 Alternativ C: Manuell användning av ChatGPT eller Claude

8.5.1 Individuell effektivitet vs organisatorisk effektivitet

Manuell användning kan fungera väl för enskilda individer, men forskning visar tydligt att:

- kvaliteten blir personberoende
- kunskap institutionaliseras inte
- variationen i svar ökar

Detta har dokumenterats i flera studier om *shadow AI* och informell AI-användning i organisationer (Kellogg et al., 2020; Weidinger et al., 2022).

8.5.2 Prompt-bördan som dold kostnad

För att uppnå konsekvent kvalitet krävs avancerade promptar, vilket i praktiken innebär:

- sökande efter rätt mall
- trial-and-error
- kognitiv belastning

Forskning om arbetsflödesavbrott visar att detta ofta äter upp den tid som automationen påstås spara (Mark et al., 2008).

8.6 Alternativ D: Integrerad AI i e-postklienter

8.6.1 Begränsad beslutsförmåga

Integrerade AI-funktioner fokuserar primärt på:

- språklig förbättring
- sammanfattning
- tonalitet

De saknar däremot:

- riskmodell
- policyförståelse
- organisatoriskt minne

→ De fungerar som skrivstöd, inte som beslutsstöd!

8.7 Alternativ E: Human-in-the-loop mailbot

8.7.1 Sammanvägd analys

I jämförelse med ovanstående alternativ utmärks mailbot-arkitekturen av att:

- begränsa AI:s beslutsmakt
- minska extern risk
- reducera kognitiv belastning
- ackumulera organisatorisk kunskap

Detta placerar lösningen i linje med modern forskning om *human-centered AI* och *responsible AI* snarare än med ren produktivitetsautomation.

8.8 Sammanfattning

Den systematiska jämförelsen visar att många AI-lösningar som framstår som attraktiva på ytan introducerar betydande organisatorisk komplexitet och risk när de sätts i drift. Särskilt gäller detta lösningar som:

- exponerar generativa svar direkt till användare
- saknar explicit human-in-the-loop
- kräver omfattande intern AI-driftkompetens

Mailbot-arkitekturen framstår i detta ljus som ett **konservativt men rationellt förstaval**, särskilt i organisationer där ansvar, legitimitet och långsiktigt förtroende är centrala.

9. Second-order effects och failure amplification

9.1 Inledning: bortom förstahandsnytta

En återkommande brist i utvärderingar av AI-system är fokus på **förstahandsnytta**: hur snabbt ett svar genereras, hur mycket manuell tid som sparas per ärende, eller hur väl systemet presterar på ett avgränsat testfall. Dessa mått är inte irrelevanta, men de är otillräckliga.

I organisatoriska sammanhang avgörs systemens långsiktiga värde i stället av **second-order effects**, det vill säga de effekter som uppstår *som följd av* att systemet används över tid. Det är här många till synes rimliga AI-lösningar visar sig vara strukturellt problematiska.

Detta avsnitt analyserar hur second-order effects uppstår i AI-stödd servicekommunikation, med särskilt fokus på email och chatbot-liknande lösningar, och varför dessa effekter ofta leder till **failure amplification** snarare än effektivisering.

9.2 Vad menas med second-order effects?

Med *second-order effects* avses här konsekvenser som inte uppstår direkt av systemets primära funktion, utan av hur systemet:

- påverkar användares beteende
- förändrar förväntningar
- omformar arbetsflöden
- skapar nya normer för vad som anses rimligt eller möjligt

I klassisk systemteori och socioteknisk forskning har man länge varnat för att tekniska interventioner i komplexa system ofta ger upphov till oavsiktliga konsekvenser som är svåra att förutse i designfasen (Perrow, 1984; Rasmussen, 1997).

AI-system som hanterar språk och kommunikation är särskilt känsliga i detta avseende, eftersom de inte bara utför arbete, utan också **medierar mening och auktoritet**.

9.3 Failure amplification: när små fel blir stora problem

Begreppet *failure amplification* används för att beskriva situationer där ett systems fel inte bara leder till ett lokalt misslyckande, utan förstärks genom efterföljande processer. I servicekommunikation tar detta ofta följande form:

1. Ett system ger ett felaktigt eller ofullständigt svar
2. Svaret uppfattas som auktoritativt
3. Användaren agerar på svaret
4. Organisationen tvingas korrigera, förklara eller göra undantag
5. Merarbete uppstår som är större än om inget svar givits

Forskning om automatiserade beslutsstöd har visat att denna typ av amplifikation är vanlig när systemets begränsningar inte är tydliga för användaren (Bainbridge, 1983; Parasuraman et al., 2000).

I praktiken innebär detta att **ett AI-system kan vara korrekt i majoriteten av fallen och ändå vara organisatoriskt skadligt**, om de fall där det har fel är tillräckligt konsekvenskänsliga.

Ett svar som är tydligt fel är lätt att ifrågasätta.
Ett svar som är nästan rätt etablerar förväntningar
som är svåra att backa från."

9.4 Auktoritet och språklig övertygelse

Språkmodeller har en egenskap som är central i sammanhanget: de producerar välformulerad, sammanhängande och ofta självsäker text. Detta är en styrka i många tillämpningar, men i servicekommunikation innebär det också en risk.

Flera studier visar att användare tenderar att tillskriva automatiserade system större auktoritet än vad som är rationellt, särskilt när systemet uttrycker sig säkert och konsekvent (Lee & See, 2004; Elish, 2019). Detta fenomen förstärks när systemet uppfattas som officiellt eller kopplat till en organisation. I praktiken betyder detta att:

- osäkerhet maskeras av språklig elegans
- villkor och undantag uppfattas som definitiva besked
- användare blir mindre benägna att ifrågasätta svaret

När ett sådant svar senare behöver korrigeras uppstår ofta frustration och misstro, inte bara mot systemet utan mot organisationen som helhet.

9.5 Förväntningsglidning över tid

En särskilt viktig second-order effect är **förväntningsglidning**. När organisationer inför AI-stöd som svarar snabbt och till synes kompetent, förändras gradvis användarnas förväntningar:

- svar förväntas komma omedelbart
- undantag uppfattas som regel
- tidigare informella svar uppfattas som bindande

Denna glidning sker ofta utan explicita beslut och blir synlig först när organisationen försöker dra tillbaka eller nyansera ett tidigare besked.

Forskning inom service management visar att återställning av förväntningar är betydligt mer kostsamt än att etablera realistiska förväntningar från början (Zeithaml et al., 1993; Tax et al., 1998).

”Förväntningar är lätta att höja, svåra att sänka

Ett AI-system som konsekvent svarar snabbt och självsäkert
sätter en norm som organisationen senare måste leva upp till,
även när förutsättningarna ändras.”

9.6 Belastningsförskjutning snarare än belastningsminskning

Ett återkommande empiriskt fynd i studier av AI i kund- och medlemsservice är att automation sällan eliminerar arbete; i stället **förskjuts arbetet**. Typiska mönster inkluderar:

- färre enkla frågor, men fler komplexa efterärenden
- mer tid per ärende när fel måste redas ut

- ökat emotionellt arbete vid konflikthantering

Detta fenomen har dokumenterats i flera studier av automatiserad kundtjänst, där införandet av chatbotar ofta leder till ökad belastning på mänskliga handläggare i de ärenden som återstår (Følstad & Brandtzæg, 2017; Deriscii & Meyer, 2022).

I detta ljus blir det tydligt att effektivitet inte kan mätas enbart i antal automatiserade svar, utan måste analyseras på systemnivå.

9.7 Varför human-in-the-loop dämpar second-order effects

Human-in-the-loop-design fungerar som en **dämpningsmekanism** mot flera av de second-order effects som beskrivits ovan. Genom att:

- hålla beslutspunkten mänsklig
- exponera osäkerhet internt snarare än externt
- låta AI generera förslag, inte besked

minskar risken för att felaktiga eller överdrivet säkra svar etablerar långsiktiga normer.

Detta innebär inte att human-in-the-loop eliminerar alla problem, men att **felen blir hanterbara**, lokala och lärande snarare än eskalerande. Ur ett systemperspektiv är detta en avgörande skillnad.

9.8 Sammanfattning

Second-order effects och failure amplification utgör ofta den avgörande skillnaden mellan AI-system som fungerar i pilotprojekt och system som fungerar i långvarig drift. I servicekommunikation, och särskilt i emailbaserade flöden, tenderar dessa effekter att vara både kraftfulla och svåra att reversera.

Den centrala slutsatsen i detta avsnitt är att **designval som begränsar AI:s auktoritet och exponeringsyta inte är defensiva, utan rationella**. Genom att medvetet dämpa vissa effekter offras kortsiktig automation till förmån för långsiktig organisatorisk hållbarhet.

Detta utgör en viktig bakgrund till nästa avsnitt, där fokus flyttas från risk till **lärande och institutionellt minne** som positiva långtidseffekter av en väl avgränsad mailbot-arkitektur.

10. Organisatoriskt lärande och institutionellt minne

10.1 Inledning: från effektivisering till kapacitetsuppbyggnad

Mycket av diskussionen kring AI i organisationer kretsar kring effektivisering: snabbare svar, färre handläggningstimmar, reducerade kostnader. Dessa aspekter är inte irrelevanta, men de fångar endast en begränsad del av den långsiktiga potentialen, och lika ofta av riskerna.

I detta avsnitt flyttas fokus från **kortfristig effektivitet** till **organisatorisk kapacitet över tid**. Mer specifikt analyseras hur olika AI-arkitekturer påverkar möjligheten till organisatoriskt lärande och uppbyggnad av institutionellt minne.

Den centrala tesen är att: *AI-system som inte ackumulerar organisatorisk kunskap tenderar att förstärka individberoende och fragmentering, även när de ger lokal produktivitetsvinst.*

10.2 Individuell intelligens vs institutionell intelligens

En välkänd distinktion inom organisationsforskning är skillnaden mellan individuell och institutionell intelligens. Individuell intelligens avser vad enskilda medarbetare vet och kan göra; institutionell intelligens avser vad organisationen som helhet kan reproducera oberoende av individer.

Forskning om organisatoriskt lärande har länge visat att (Argyris & Schön, 1978; Levitt & March, 1988):

- organisationer inte ”lär sig” automatiskt
- kunskap som inte externaliseras förblir skör
- personalomsättning ofta leder till kompetensförlust snarare än utveckling

I kontexten AI-stödd servicekommunikation blir denna distinktion särskilt tydlig. Lösningar som bygger på individuell användning av generativa verktyg, exempelvis manuellt användande av ChatGPT, tenderar att:

- förstärka skickliga individers produktivitet
- lämna organisationens kollektiva förmåga oförändrad
- göra kvaliteten beroende av vem som råkar hantera ett ärende

Ur ett organisatoriskt perspektiv är detta en svag form av lärande.

10.3 Varför många AI-lösningar inte ger organisatoriskt lärande

Trots att generativa AI-system hanterar stora mängder text och interaktioner leder de ofta inte till organisatoriskt lärande. Det finns flera skäl till detta.

10.3.1 Brist på struktur

Många AI-lösningar behandlar varje interaktion som isolerad. Även om data tekniskt sett finns lagrad, saknas ofta:

- explicit klassificering
- koppling mellan ärendetyper
- representation av osäkerhet och risk

Utan sådan struktur är det svårt att dra systematiska slutsatser.

10.3.2 Avsaknad av feedbackloopar

I många system finns ingen mekanism för att fånga upp:

- när AI-svar modifieras
- varför de modifieras
- vilka typer av fel som återkommer

Forskning om *learning systems* visar att utan explicita feedbackloopar sker inget robust lärande, oavsett mängden data (Sutton & Barto, 2018).

10.3.3 Överfokus på output

När fokus ligger på att producera svar snarare än att förstå ärenden reduceras möjligheten att identifiera mönster i verksamheten. Detta är en klassisk fälla i både DSS och expertssystem, dokumenterad redan i tidiga studier (Ackoff, 1989).

10.4 Mailboten som lärande artefakt

I kontrast till ovanstående är mailbot-arkitekturen designad för att fungera som en **lärande artefakt** i organisationen.

Med detta avses att systemet:

- strukturerar inkommande ärenden konsekvent
- gör riskbedömningar explicita
- synliggör var mänsklig bedömning krävs
- fångar upp hur förslag justeras i praktiken

Över tid innebär detta att organisationen inte bara svarar på mail, utan också gradvis bygger upp en mer artikulerad förståelse av:

- vilka frågor som är oklara
- var policys brister
- vilka undantag som är återkommande snarare än exceptionella

Detta ligger nära det som i litteraturen beskrivs som *double-loop learning*, där organisationen inte bara justerar handlingar, utan även ifrågasätter underliggande antaganden (Argyris, 1977).

Lärande uppstår inte ur data, utan ur struktur

Data i sig skapar inte organisatoriskt lärande. Det gör Strukturerade tolkningar av återkommande beslut.

10.5 Institutionellt minne i praktiken

Institutionellt minne handlar inte enbart om arkivering, utan om **återanvändbar förståelse**. I mailbot-scenariot manifesteras detta bland annat genom:

- konsistenta svarsförslag över tid
- minskad variation mellan handläggare
- möjlighet att identifiera när praxis förändras

Detta har flera praktiska konsekvenser:

- nya medarbetare kommer snabbare in i arbetet
- beroendet av informella ”nyckelpersoner” minskar
- organisationen blir mindre sårbar för personalomsättning

Forskning inom *knowledge management* visar att just denna typ av implicit kunskap är den svåraste att bevara utan tekniskt stöd (Nonaka & Takeuchi, 1995; Alavi & Leidner, 2001).

10.6 Konsekvenser för styrning och utveckling

När organisationen får bättre synlighet i sina egna kommunikationsmönster uppstår också nya möjligheter för styrning och förbättring. Exempelvis kan ledningen:

- identifiera vilka policyområden som genererar mest osäkerhet
- prioritera var tydligare riktlinjer behövs
- fatta beslut baserat på faktisk belastning snarare än anekdot

Detta förutsätter dock att AI-systemet är designat för att **göra sin egen osäkerhet och sina begränsningar synliga**, snarare än att maskera dem bakom välformulerade svar.

10.7 Sammanfattning

I detta avsnitt har vi argumenterat för att den kanske viktigaste långsiktiga effekten av en human-in-the-loop mailbot inte är reducerad handläggningstid, utan ökad organisatorisk mognad. Genom att strukturera, synliggöra och ackumulera kunskap om den egna verksamheten kan organisationen gradvis flytta sig från reaktiv hantering till mer reflekterad styrning.

Detta perspektiv skiftar fokus från AI som verktyg till AI som **organisatorisk infrastruktur**. Ett sådant skifte kräver återhållsamhet i automation, men belönar organisationen med stabilitet, lärande och minskad sårbarhet över tid.

11. Styrning, ansvar och governance

11.1 Inledning: varför governance inte är ett tillägg

I många AI-initiativ behandlas governance som ett senare steg, ofta reducerat till frågor om juridisk efterlevnad, dataskydd eller etikpolicyer. Ett sådant angreppssätt är problematiskt i serviceorganisationer där AI påverkar daglig kommunikation, beslutsfattande och relationer till medlemmar eller kunder.

I detta avsnitt utgår vi från en annan premiss: **styrning och ansvar måste vara inbyggda i systemets arkitektur från början**. Detta gäller i synnerhet system som hanterar språk och kommunikation, eftersom dessa system inte bara producerar output, utan också formar tolkningar och förväntningar.

11.2 Ansvar kan inte delegeras bort

En central princip inom både organisationsstyrning och rättsteori är att ansvar inte kan automatiseras bort. Även när beslut fattas med tekniskt stöd förblir ansvaret mänskligt och organisatoriskt.

Forskning om ansvar i automatiserade system visar att försök att ”flytta” ansvar till tekniska artefakter ofta leder till ansvarsdiffusion snarare än ansvarsfrihet (Matthias, 2004; Floridi et al., 2018). I praktiken innebär detta att:

- organisationen alltid hålls ansvarig för systemets effekter
- teknisk komplexitet inte accepteras som ursäkt
- användare förväntar sig tydliga avsändare och beslutsfattare

I emailbaserad servicekommunikation är detta särskilt tydligt. Ett svar som uppfattas som ett besked från organisationen, oavsett om det genererats av en människa eller ett system, tillskrivs organisationen ansvar.

11.3 Governance-utmaningar i generativa AI-system

Generativa AI-system introducerar flera specifika governance-utmaningar:

1. **Otydliga beslutsgränser**

När analys, bedömning och svar sammanfaller i en och samma modell blir det svårt att avgöra var beslut faktiskt fattas.

2. **Begränsad spårbarhet**

Probabilistiska modeller saknar ofta tydliga beslutsloggar som kan granskas i efterhand.

3. **Svårighet att justera beteende selektivt**

Små ändringar i promptar eller modellparametrar kan få oproportionerliga effekter.

Dessa problem är väl dokumenterade i forskning om *black-box systems* och *accountability gaps* i AI (Burrell, 2016; Selbst et al., 2019).

“Governance börjar i arkitekturen

Styrning som inte är tekniskt inbyggd blir i praktiken en efterhandsreaktion.”

11.4 Mailbot-arkitekturen som governance-vänlig design

Mailbot-arkitekturen adresserar ovanstående utmaningar genom flera medvetna designval.

11.4.1 Tydlig separering av roller

Genom att separera:

- analys
- riskbedömning
- generering av förslag
- beslut och utskick

skapas tydliga gränser för var ansvar ligger. Detta gör det möjligt att i efterhand svara på frågor som:

- varför ett ärende eskalerades
- varför ett visst förslag genererades
- vem som fattade det slutliga beslutet

Denna typ av spårbarhet är central i både klassisk intern styrning och modern AI-governance (OECD, 2019; EU AI Act, pågående).

11.4.2 Mänsklig avsändare och legitimt beslutsfattande

I mailbot-scenariot är det alltid en människa som:

- godkänner eller modifierar svar
- står som avsändare
- bär det formella ansvaret

Detta är inte bara en juridisk detalj, utan en fråga om legitimitet. Forskning om organisatorisk legitimitet visar att mottagare accepterar även negativa beslut lättare när de uppfattar att beslutsfattandet är begripligt och ansvarsburet (Suchman, 1995).

11.5 Spårbarhet, transparens och revision

En ofta förbisedd aspekt av AI-system är behovet av **revision**, inte bara i teknisk mening, utan organisatoriskt.

Mailbot-arkitekturen möjliggör detta genom att:

- logga klassificeringar och riskbedömningar
- spara versioner av svarsförslag
- koppla slutligt utskick till mänskligt beslut

Detta gör det möjligt att:

- analysera återkommande problem
- identifiera systematiska osäkerheter
- justera regler och mallar på informerad grund

Forskning om *algorithmic auditing* pekar på att denna typ av strukturerad transparens är avgörande för långsiktig tillit till AI-system (Sandvig et al., 2014; Raji et al., 2020).

”Transparens är inte insyn i modellen, utan insyn i beslutsvägar

För de flesta organisationer är det viktigare att kunna förklara varför ett beslut fattades än exakt hur en modell räknade.”

11.6 Governance över tid: från kontroll till styrning

En viktig poäng är att governance inte är statisk. I takt med att organisationen lär sig mer om sina egna kommunikationsmönster kan styrningen förfinas. I mailbot-scenariot innebär detta att:

- riskkriterier kan justeras
- vissa ärendetyper kan få mer eller mindre automatiskt stöd
- policyförändringar snabbt kan återspeglas i systemet

Detta står i kontrast till många generiska AI-lösningar där förändringar kräver omfattande omträning eller externa leverantörsinsatser.

11.7 Sammanfattning

Styrning, ansvar och governance är inte sekundära frågor i AI-stödd servicekommunikation, utan centrala designkriterier. System som saknar tydliga ansvarslinjer, spårbarhet och mänsklig beslutsförankring riskerar att skapa organisatorisk osäkerhet även när de fungerar tekniskt.

Mailbot-arkitekturen visar hur governance kan realiseras genom arkitektur snarare än genom efterhandsreglering. Genom att hålla beslutsfattandet mänskligt, göra risk och osäkerhet explicita och möjliggöra revision över tid skapas förutsättningar för både ansvarstagande och lärande.

Detta avsnitt utgör därmed en brygga till det avslutande avsnittet om **införandestrategi**, där fokus flyttas från designprinciper till praktiska överväganden kring hur ett sådant system introduceras utan att skapa onödig friktion.

Detta avsnitt utgör därmed en brygga till det avslutande avsnittet om **införandestrategi**, där fokus flyttas från designprinciper till praktiska överväganden kring hur ett sådant system introduceras utan att skapa onödig friktion.

12. Införandestrategi

12.1 Inledning: varför införandet är ett systemproblem

Införandet av ett AI-stött system i en serviceorganisation är inte primärt en teknisk fråga. De flesta tekniska komponenter kan göras fungerande relativt snabbt. Det som avgör utfallet är i stället hur införandet påverkar:

- arbetsflöden
- ansvarsfördelning
- förväntningar hos användare och mottagare
- organisationens egen självbild

Forskning om införande av informationssystem visar konsekvent att misslyckanden sällan beror på teknik i sig, utan på bristande anpassning mellan system, organisation och praktik (Markus, 1983; Orlikowski, 2000). Detta gäller i särskilt hög grad för generativa AI-system, eftersom de inte bara stödjer arbete utan också producerar kommunikation som uppfattas som meningsfull och auktoritativ.

Utgångspunkten för detta avsnitt är därför att **införandet måste vara lika genomtänkt som arkitekturen**.

12.2 Börja där risken är lägst, inte där vinsten ser störst ut

Ett vanligt misstag i AI-initiativ är att börja med de mest synliga eller imponerande tillämpningarna. Detta skapar ofta initial entusiasm men medför samtidigt hög risk.

I en mailbot-kontext innebär en riskmedveten strategi i stället att:

- börja med ärendetyper som är frekventa men låg risk
- undvika undantags- och policykänsliga frågor i initialfasen
- använda systemet internt under en längre period innan eventuella automatiseringsgrader höjs

Denna strategi är i linje med forskning om *incremental deployment* i komplexa system, där gradvis införande visat sig minska både teknisk och organisatorisk risk (Rasmussen, 1997; Reason, 2000).

”Börja inte där det ser mest imponerande ut

I AI-projekt är det ofta rationellt att börja där ett misslyckande kostar minst, inte där nyttan på pappret ser störst ut.”

12.3 Tydliggör vad systemet inte ska göra

En ofta underskattad del av införandet är att **explicit definiera systemets begränsningar**, inte bara dess funktioner.

I mailbot-scenariot bör detta inkludera tydliga ställningstaganden kring att systemet:

- inte fattar beslut om utskick
- inte ger bindande besked externt
- inte ersätter mänskligt ansvar
- inte är ett substitut för policyarbete

Dessa avgränsningar bör inte bara vara tekniskt implementerade, utan också kommunicerade internt. Forskning om teknikanvändning visar att otydliga förväntningar är en stark prediktor för senare frustration och kringgående av system (Venkatesh et al., 2003).

12.4 Intern användning före extern exponering

En central rekommendation i detta white paper är att **hålla AI-stödet internt under införandets första faser**.

Detta innebär att:

- svarsförslag endast ses av personal
- systemets brister upptäcks utan extern konsekvens
- organisationen får möjlighet att kalibrera riskbedömning och mallar

Flera studier av chatbotinföranden visar att system som tidigt exponeras externt tenderar att skapa negativa förväntningar som är svåra att korrigera i efterhand (Følstad & Brandtzæg, 2017; Luger & Sellen, 2016).

12.5 Utbildning som kalibrering, inte som träning

Införande av ett human-in-the-loop-system kräver utbildning, men inte i traditionell mening. Det handlar mindre om att lära användarna *hur systemet fungerar tekniskt*, och mer om att kalibrera deras förståelse för:

- vad systemet är bra på

- var det är osäkert
- när mänsklig bedömning är avgörande

Utbildningen bör därför fokusera på:
- tolkning av riskmarkeringar
- hur svarsförslag ska användas och justeras
- hur feedback till systemet fångas upp

Detta ligger nära forskning om *calibrated trust* i människa–AI-samspel, där målet inte är maximal tillit utan korrekt tillit (Lee & See, 2004; Hoff & Bashir, 2015).

”Målet är inte tillit, utan kalibrerad tillit

Ett bra AI-system är inte ett system som användarna litar blint på, utan ett system vars begränsningar de förstår.”

12.6 Mät rätt saker från början

En annan vanlig fallgrop är att mäta fel saker. I tidiga skeden är det sällan meningsfullt att fokusera på:
- antal automatiserade svar
- genomsnittlig svarstid

Mer informativa mått i ett mailbot-införande är exempelvis:
- andel ärenden som eskaleras
- variation i hur svarsförslag modifieras
- återkommande riskklassificeringar
- upplevd kognitiv belastning hos handläggare

Dessa mått ger insikt i hur systemet faktiskt påverkar arbetet, snarare än hur effektivt det ser ut på ytan. Forskning om *socio-technical metrics* pekar på vikten av sådana kvalitativa och processnära mått i tidiga faser (Amershi et al., 2019).

12.7 Iterativ justering och kontrollerad expansion

Efter en initial period av intern användning och kalibrering kan systemets roll gradvis utökas. Detta bör dock ske kontrollerat och med tydliga kriterier.

Exempel på sådana kriterier kan vara:
- stabil riskklassificering över tid
- minskad variation i svarsförslag
- identifierade policyområden som är tillräckligt tydliga

Expansion bör ses som ett resultat av mognad, inte som ett mål i sig.

12.8 Sammanfattning

Införandet av en human-in-the-loop mailbot bör betraktas som ett organisatoriskt förändringsarbete snarare än ett tekniskt projekt. Genom att börja försiktigt, vara tydlig med begränsningar, hålla systemet internt i tidiga faser och fokusera på kalibrering snarare än automation kan organisationen minska risk och bygga långsiktig kapacitet.

Den centrala poängen är att **ett genomtänkt införande inte saktar ned utvecklingen, utan förhindrar att organisationen springer i fel riktning**.

13. Avslutande syntes och slutsats

13.1 Från teknikval till designval

Detta white paper har medvetet undvikit att formulera frågan som ett val mellan olika tekniska lösningar. I stället har analysen konsekvent utgått från hur AI-system fungerar som delar av sociotekniska helheter, där teknik, organisation, ansvar och praktik samverkar.

Den samlade analysen leder till en tydlig slutsats:
i serviceorganisationer där email utgör en central besluts- och kommunikationsyta är det inte modellens råa kapacitet som är den begränsande faktorn, utan hur denna kapacitet placeras, begränsas och styrs.

Detta gör valet av *arkitektur* viktigare än valet av *modell*.

13.2 Varför ambition ofta missriktas

Ett återkommande tema i diskussioner om AI är att organisationer tenderar att överskatta värdet av autonomi och underskatta kostnaden för konsekvenser. I synnerhet gäller detta för lösningar som:

- exponerar generativa svar direkt till externa användare
- saknar explicit human-in-the-loop
- förutsätter intern drift av komplex AI-infrastruktur
- bygger på antagandet att bättre modeller automatiskt leder till bättre utfall

Analysen i detta dokument visar att dessa antaganden är svagt grundade i såväl forskning som praktisk erfarenhet, särskilt i kontexter där beslut är kontextberoende, ansvarsbärande och relationspåverkande.

I stället framträder ett annat mönster:
de mest robusta AI-tillämpningarna är ofta de som är mest återhållsamma i vad de automatiserar.

13.3 Human-in-the-loop som rationell slutpunkt, inte mellanläge

En central poäng i dokumentet är att *human-in-the-loop* inte bör betraktas som ett övergångsstadium på väg mot full automation. I många organisatoriska domäner är det tvärtom en stabil slutpunkt.

För emailbaserad servicekommunikation innebär detta att:

- mänsklig bedömning inte är ett temporärt hinder
- ansvar inte är en restpost som kan ”lösas senare”
- legitimitet och spårbarhet är funktionella krav, inte etiska tillägg

Mailbot-arkitekturen visar hur human-in-the-loop kan realiseras på ett sätt som inte bromsar arbetet, utan i stället **flyttar människans roll från formulering till omdöme**. Detta är en kvalitativ förändring av arbetets karaktär, inte bara en kvantitativ effektivisering.

13.4 Mailboten som organisatorisk infrastruktur

Sett i ett längre perspektiv framträder mailboten inte primärt som ett verktyg för att hantera email, utan som en form av organisatorisk infrastruktur.

Genom att:

- strukturera inkommande kommunikation
- synliggöra risk och osäkerhet
- ackumulera kunskap om faktisk praxis
- möjliggöra spårbarhet och revision

bidrar systemet till att stärka organisationens kollektiva handlingsförmåga. Detta skiljer sig principiellt från lösningar som fokuserar på individuell produktivitet eller punktinsatser.

I denna mening kan mailboten förstås som ett **reflekterande lager** ovanpå den dagliga verksamheten, där organisationen gradvis lär känna sig själv bättre genom sina egna beslut.

13.5 Konservatism som designprincip

Ett ord som återkommer implicit i detta dokument är *konservatism*, inte i politisk mening, utan i ingenjörsmässig. Den föreslagna arkitekturen är konservativ genom att:

- begränsa AI:s beslutsmakt
- prioritera förutsägbarhet framför maximal autonomi
- föredra explicita kontrollpunkter framför implicit intelligens

Denna konservatism ska inte förväxlas med teknikmotstånd. Tvärtom är den ett uttryck för teknisk mognad, där system designas med full medvetenhet om både sina styrkor och sina begränsningar.

13.6 Slutsats

Den samlade slutsatsen av detta white paper är följande:

För organisationer där email utgör en central kommunikations- och beslutsyta är en human-in-the-loop mailbot ett rationellt förstaval för AI-stöd, inte därför att tekniken ännu är otillräcklig, utan därför att organisationens krav på ansvar, legitimitet och långsiktig hållbarhet är höga.

Att börja med en sådan lösning är inte att sänka ambitionen, utan att **rikta ambitionen rätt**.

Detta dokument har inte argumenterat för mindre AI, utan för **bättre placerad AI**.

Referenser

Sociotekniska system, organisation och arbete

- Ackoff, R. L. (1989). *From data to wisdom*. Journal of Applied Systems Analysis, 16, 3–9.
- Argyris, C. (1977). *Double loop learning in organizations*. Harvard Business Review, 55(5), 115–125.
- Argyris, C., & Schön, D. (1978). *Organizational Learning: A Theory of Action Perspective*. Addison-Wesley.
- Bainbridge, L. (1983). *Ironies of automation*. Automatica, 19(6), 775–779.
- Orlikowski, W. J. (1992). *The duality of technology: Rethinking the concept of technology in organizations*. Organization Science, 3(3), 398–427.
- Orlikowski, W. J. (2000). *Using technology and constituting structures*. Organization Science, 11(4), 404–428.
- Perrow, C. (1984). *Normal Accidents*. Basic Books.
- Rasmussen, J. (1997). *Risk management in a dynamic society*. Safety Science, 27(2–3), 183–213.
- Reason, J. (2000). *Human error: models and management*. BMJ, 320, 768–770.
- Suchman, L. (1987). *Plans and Situated Actions*. Cambridge University Press.
- Suchman, M. C. (1995). *Managing legitimacy*. Academy of Management Review, 20(3), 571–610.

Beslutsstöd, human-in-the-loop och automation bias

- Simon, H. A. (1960). *The New Science of Management Decision*. Harper & Row.
- Sprague, R. H., & Carlson, E. D. (1982). *Building Effective Decision Support Systems*. Prentice Hall.
- Parasuraman, R., & Riley, V. (1997). *Humans and automation: Use, misuse, disuse, abuse*. Human Factors, 39(2), 230–253.
- Parasuraman, R., Sheridan, T. B., & Wickens, C. D. (2000). *A model for types and levels of human interaction with automation*. IEEE Transactions on Systems, Man, and Cybernetics, 30(3), 286–297.
- Lee, J. D., & See, K. A. (2004). *Trust in automation*. Human Factors, 46(1), 50–80.
- Horvitz, E. (1999). *Principles of mixed-initiative user interfaces*. Proceedings of CHI.
- Endsley, M. R. (2017). *From here to autonomy*. Human Factors, 59(1), 5–27.

Generativ AI, risk, governance och ansvar

- Amodei, D., et al. (2016). *Concrete problems in AI safety*. arXiv:1606.06565.
- Amershi, S., et al. (2019). *Guidelines for human–AI interaction*. Proceedings of CHI.
- Bender, E. M., et al. (2021). *On the dangers of stochastic parrots*. Proceedings of FAccT.
- Burrell, J. (2016). *How the machine "thinks"*. Big Data & Society.
- Elish, M. C. (2019). *Moral crumple zones*. Engaging Science, Technology, and Society, 5, 40–60.
- Floridi, L., et al. (2018). *AI4People—An ethical framework for a good AI society*. Minds and Machines, 28, 689–707.
- Kellogg, K. C., Valentine, M. A., & Christin, A. (2020). *Algorithms at work*. Academy of Management Annals, 14(1), 366–410.
- Rahwan, I., et al. (2019). *Machine behaviour*. Nature, 568, 477–486.
- Raji, I. D., et al. (2020). *Closing the AI accountability gap*. Proceedings of FAccT.

- Sandvig, C., et al. (2014). *Auditing algorithms*. Data and Discrimination Conference.
- Selbst, A. D., et al. (2019). *Fairness and abstraction in sociotechnical systems*. Proceedings of FAccT.
- Shneiderman, B. (2020). *Human-centered artificial intelligence*. Oxford University Press.
- Weidinger, L., et al. (2022). *Ethical and social risks of harm from language models*. arXiv:2112.04359.

Servicekommunikation, chatbotar och empiriska studier

- Følstad, A., & Brandtzæg, P. B. (2017). *Chatbots and the new world of HCI*. Interactions, 24(4), 38–42.
- Deriscii, O., & Meyer, M. (2022). *Automation and customer dissatisfaction in AI-based service*. Journal of Service Research.
- Luger, E., & Sellen, A. (2016). *Like having a really bad PA*. Proceedings of CHI.
- Mark, G., Gonzalez, V. M., & Harris, J. (2008). *No task left behind?* Proceedings of CHI.
- Zeithaml, V. A., Berry, L. L., & Parasuraman, A. (1993). *The nature and determinants of customer expectations*. Journal of the Academy of Marketing Science.
- Tax, S. S., Brown, S. W., & Chandrashekaran, M. (1998). *Customer evaluations of service complaint experiences*. Journal of Marketing.

Infrastruktur, LLM-drift och systemkostnader

- Brown, T. B., et al. (2020). *Language models are few-shot learners*. NeurIPS.
- Narayanan, A., et al. (2021). *Understanding the costs of machine learning systems*. Communications of the ACM.
- Patterson, D., et al. (2021). *Carbon emissions and large neural network training*. arXiv:2104.10350.
- Mozilla Foundation (2023). *AI and consumer harm: Case studies*.
- OECD (2019). *Artificial Intelligence and Public Policy*. OECD Publishing.